



# 머신러닝 프로젝트

RFM 분석 기반 세분화 전략 및 머신러닝 기반 재구매 예측

# Contents

## 01 프로젝트 개요

- instacart 소개
- 분석 배경 및 목표

## 02 데이터 소개

- instacart Market Basket Dataset
- 데이터 탐색

## 03 RFM & 고객 세분화

- RFM 분석 개요
- 파생 변수 생성  
및 고객 등급 분류

## 04 고객 세분화별 EDA

- 그룹별 insight

## 05 재구매 예측 모델

- Feature Engineering
- Modeling
- Evaluation

## 06 결론 및 제안

- 분석 결과 요약
- 전략 제안 및 기대효과

## 01 프로젝트 개요

### Instacart 소개



Instacart는 미국과 캐나다에서 운영되는 온라인 식료품 배달 서비스로, 사용자가 웹사이트나 모바일 앱을 통해 주문한 식료품을 지역 슈퍼마켓에서 직접 픽업하거나 배송 받을 수 있습니다.

#### ✓ 2시간 이내 배송 서비스 제공

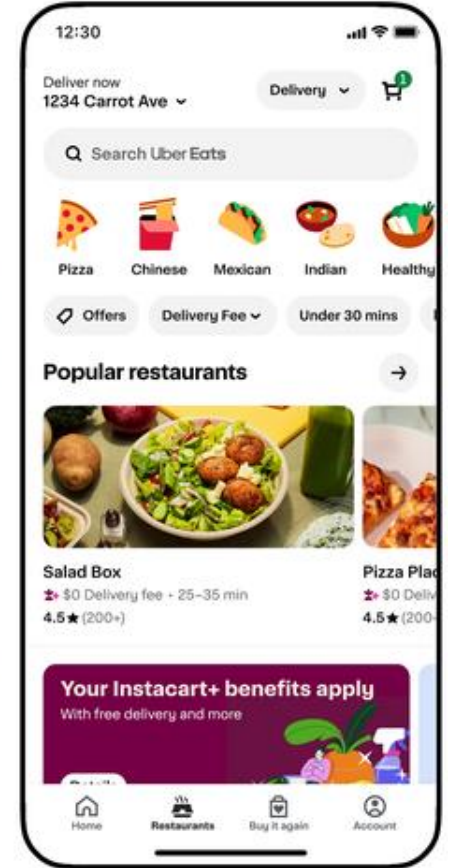
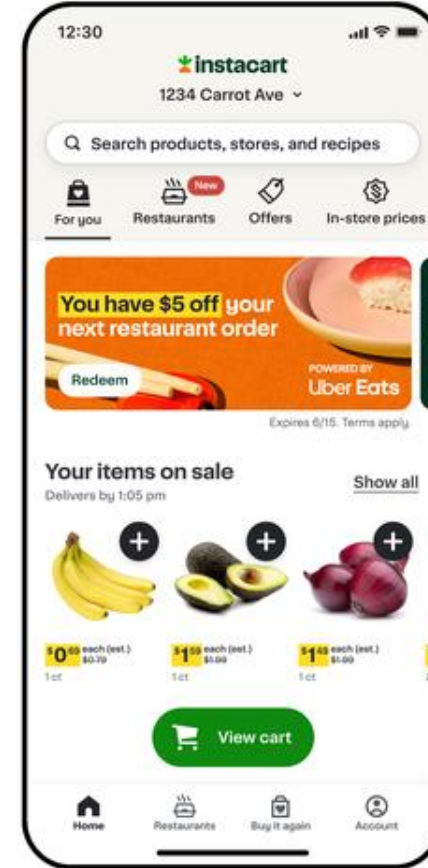
많은 지역에서 2시간 이내의 배송 서비스를 제공하여 고객이 주문하면 바로 식료품을 배달 받을 수 있습니다.

#### ✓ 로컬 슈퍼마켓과의 파트너십

다양한 지역의 슈퍼마켓과 대형 마트들과 협력하여 고객이 선호하는 특정 마트에서 직접 구매 가능합니다.

#### ✓ 개인화된 장바구니 상품 추천

고객의 구매 기록과 선호도를 바탕으로 추천 시스템을 활용하여, 고객이 원하는 상품을 쉽게 재주문할 수 있습니다.



구매 기록과 선호도를 바탕으로 신속하게 식료품을 배달하는 온라인 플랫폼, instacart

## 01 프로젝트 개요

분석 배경 및 목표

### 분석 배경

#### 고객 세분화의 필요성

다양한 고객층은 각기 다른 구매 패턴과 선호도를 가지고 있으며, 이로 인해 고객 맞춤형 서비스를 제공하기 위한 세분화가 필요합니다.

#### 재구매 및 충성도 향상

특정 상품에 대한 재구매 빈도를 높이고 충성 고객을 늘리는 것은 Instacart의 지속적인 성장을 위해 필수적입니다.

#### 데이터 기반 맞춤형 추천 시스템

방대한 구매 데이터를 바탕으로, 고객 맞춤형 상품 추천을 통해 사용자 경험을 개선하고 고객 만족도를 높이는 것이 중요합니다.

### 분석 목표

#### 고객 세분화 및 맞춤형 전략 제시

고객의 구매 주기와 빈도를 분석하여 고객을 세분화하고, 각 등급별 맞춤형 마케팅 전략을 수립합니다.

#### 고객 충성도와 매출 성장

충성 고객 전환 가능성이 높은 신규 고객을 발굴하여, 장기적으로 Instacart의 매출 성장에 기여할 전략을 도출합니다.

#### 상품별 재구매 여부 예측

머신러닝 모델을 활용해 고객의 상품 재구매 가능성을 예측하고, 이를 바탕으로 추천 시스템을 고도화하여 고객의 편의를 증대합니다.

**고객 세분화를 통한 맞춤형 재구매 예측**으로 Instacart의 충성도와 매출 성장 기여

## 02 데이터 소개

Instacart Market Basket Dataset

### Data set

orders columns	Description
order_id	각 주문에 부여된 고유 식별자입니다.
user_id	주문을 한 고객의 고유 식별자입니다.
eval_set	과거 주문 데이터 또는 모델 학습에 적용되는 세트인지 알려줍니다.
order_number	해당 고객이 주문한 횟수로, 몇 번째로 주문한 것인지 알 수 있습니다.
order_dow	주문한 요일을 나타내며 일요일부터 토요일까지 매핑 되어있습니다.
order_hour_of_day	주문한 시간으로 0시에서 24시간 정수로 표현되어 있습니다.
days_since_prior_order	이전 주문 이후 몇일이 지났는지 나타내며, 주문 주기와 재구매 간격 분석할 수 있습니다.

order_products	Description
order_id	-
product_id	상품의 고유 식별자입니다.
add_to_cart_order	몇 번째로 장바구니에 담았는지 알 수 있습니다.
reordered	재구매된 상품인지를 나타냅니다

products
product_id
product_name
department_id
aisle_id

aisles
aisle_id
aisle

deparments
department_id
department

.....

.....

.....

.....

.....

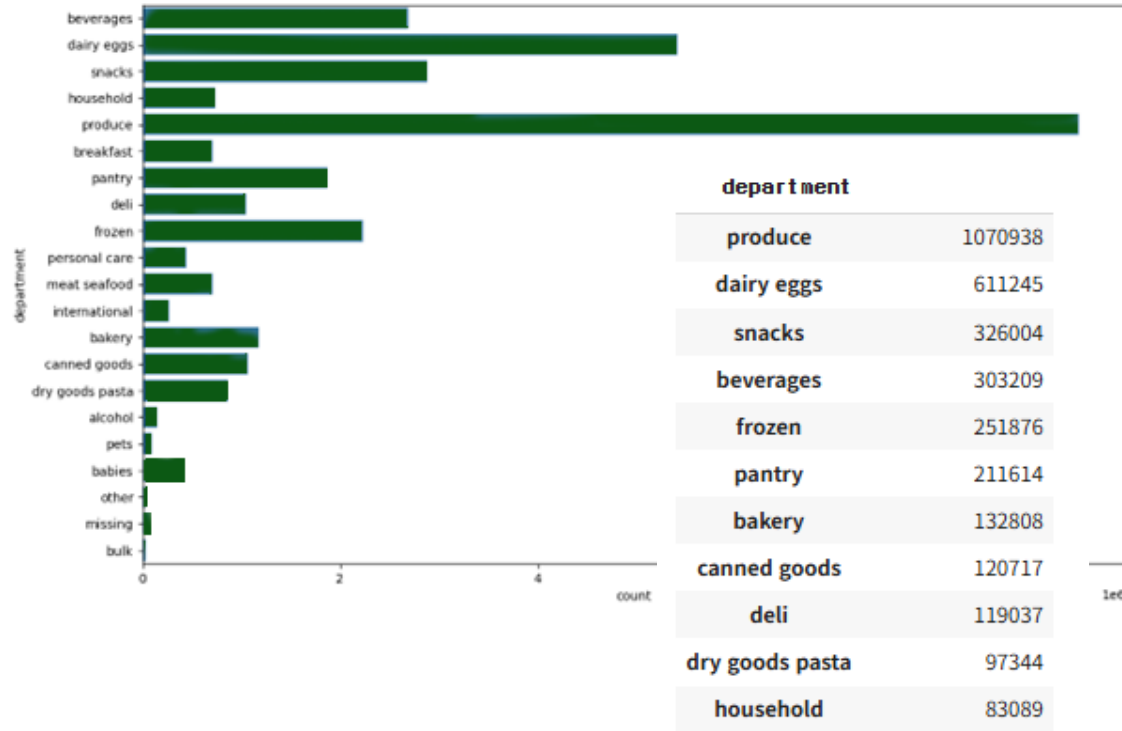
.....

## 02 데이터 소개

데이터 탐색

### Q1. 가장 많이 주문된 대분류 상품(Department)은?

| department 별 주문 수 |



**produce 농산물** 구매 빈도가 매우 높은 것으로 확인


Dairy eggs, snacks, beverage, frozen 순서로 많이 구매

### Q2. 가장 많이 주문된 소분류 상품(Product)은?

Top 1. Banana (472,565건)

Top 2. Bag of Organic Bananas (379,450건)

Top 3. Organic Strawberries (264,683건)



| aisle 별 주요 구매 상품 워드 cloud 그래프 |

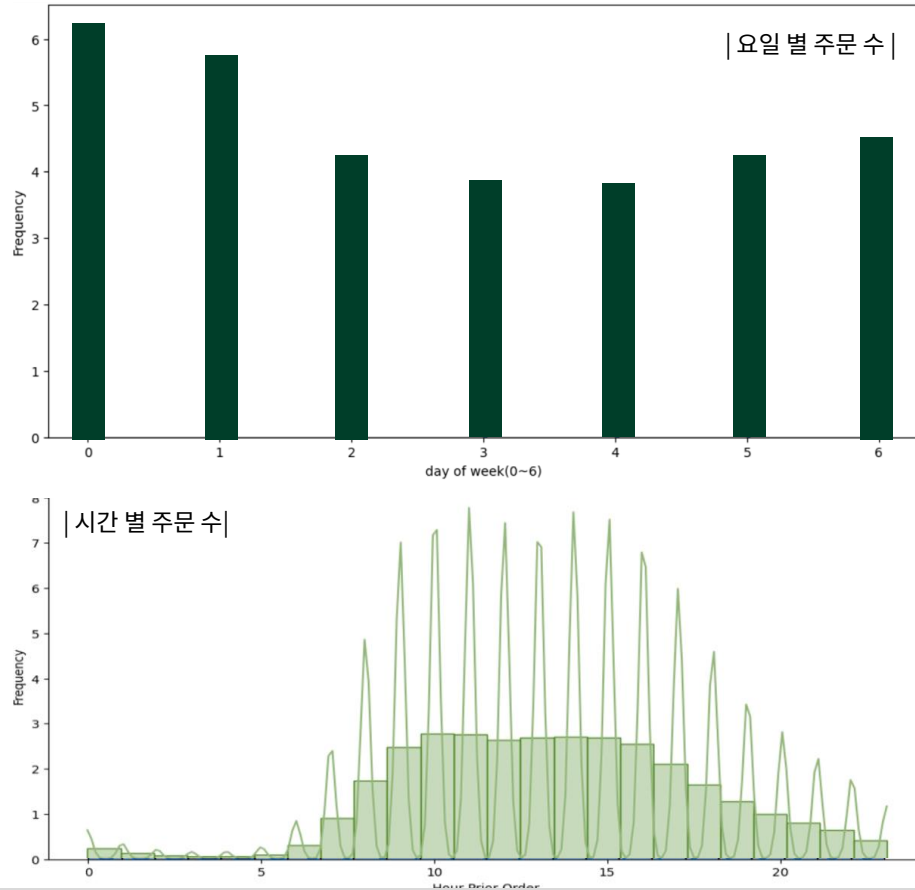
특히 **Fruits & vegetables** 전체 주문수 대비 약 30% 차지

instacart의 **주요 고객 선호 상품**

## 02 데이터 소개


데이터 탐색

### Q3. 가장 많이 주문하는 요일과 시간대는?



**일요일, 월요일**에 높은 구매율을 보이며,  
**오전 9시에서 오후 17시**까지 활발한 주문 수를 보여줌

### Q4. 재구매까지 걸리는 기간은?




대부분 재구매를 경험했으며, 주문 물품 약 60%가 재구매 상품  
**주로 7일 이내 또는 30일 주기**로 많은 재구매가 일어남

## 02 데이터 소개

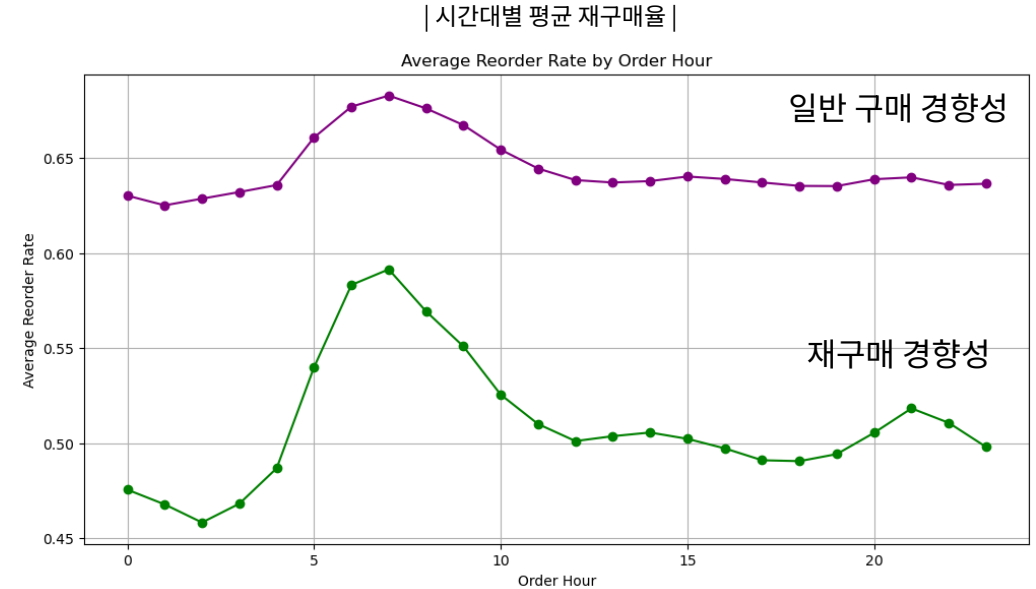
데이터 탐색

### Q4 - 1. 가장 많이 재주문된 대분류 상품(Department)은?



최다 구매 제품군인 Produce 보다 **Dairy eggs**가 재구매율이 가장 높으며 소분류 상품은 TOP 10 은 주로 Produce 농산물

### Q4 - 2. 재구매가 가장 많이 일어나는 시간대는?



기존 경향성 = 주문수 & 재구매율 양의 관계

재구매 경향성 = 주문수 & 재구매율 음의 관계


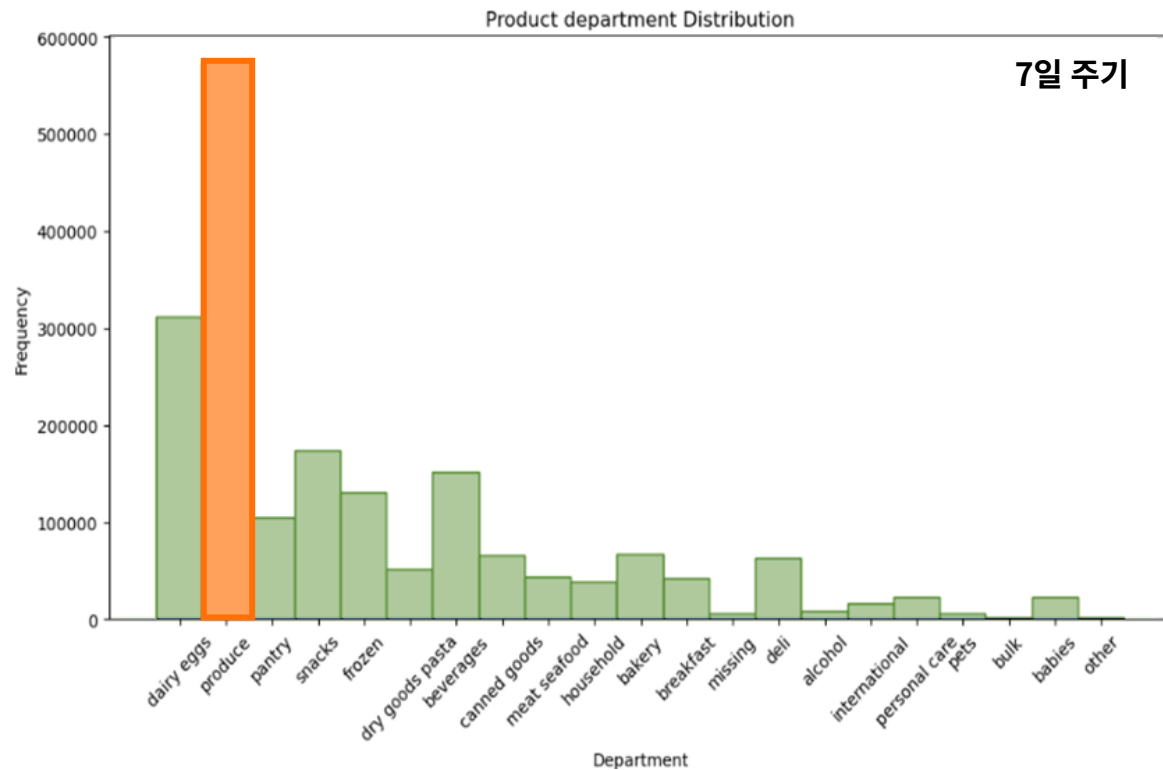
시간별 구매 패턴이 비슷하나  
특히 **6-7시, 21시**에 재구매율이 높음을 확인



## 02 데이터 소개


데이터 탐색

### Q4 - 3. 주기별 재구매 인기 상품은?



7일 주기 구매 빈도가 가장 높은 물품은 **Produce** , 30일 이후 주기 구매 빈도가 가장 높은 물품은 **Personal care**

### Q5. 주문 시 평균 장바구니 물품 수는?

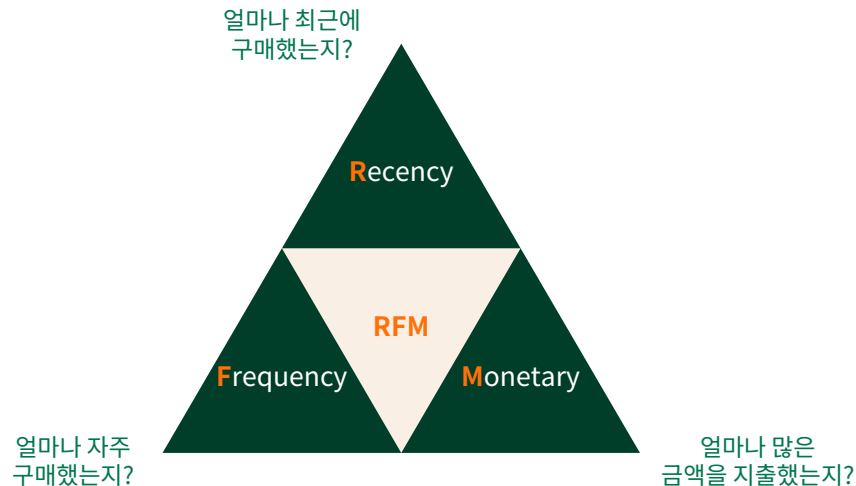


한 번 주문 시 **평균 8개** 정도의 물품을 주문하며, 빠른 장바구니 추가가 재구매율 향상에 기여

## 03 RFM & 고객 세분화

### RFM 분석 개요

#### RFM이란?



고객별로 얼마나 최근에, 자주, 많은 금액 지출했는지 여부에 따라  
고객들의 분포를 확인하거나 그룹(등급)을 나누어 분류하는 분석 기법

#### 파생변수 생성

##### RFM 변수 도출 1단계

```
1 rfm_model = df.groupby('user_id').agg(  
2  
3     # r = 고객별로 최신 주문까지 걸린 일(시간)  
4     recency=('days_since_prior_order', 'last'),  
5  
6     # f = 주문한 순서 컬럼을 이용하여 최대값  
7     frequency=('order_number', 'max'),  
8  
9     # m = 고객이 주문한 전체 상품 수  
10    monetary=('product_name', 'count')  
11  
12 ),reset_index()  
13  
14 rfm_model  
  
1 # 가중치 부여  
2 weight_r = 0.2  
3 weight_f = 0.4  
4 weight_m = 0.4  
5  
6 #rfm 점수 계산  
7 rfm_model['rfm_score'] = (rfm_model['recency'] * weight_r +  
8                             rfm_model['frequency'] * weight_f +  
9                             rfm_model['monetary'] * weight_m)  
10  
11 rfm_model.head(20)
```

	user_id	recency	frequency	monetary	rfm_score
0	1	28	5	8	10.8
1	3	9	2	9	6.2
2	4	15	4	2	5.4
3	5	19	4	12	10.2
4	6	6	2	7	4.8
5	7	3	19	40	24.2
6	9	0	1	30	12.4
7	10	14	4	76	34.8
8	12	30	5	22	16.8
9	13	9	4	5	5.4
10	15	14	14	5	10.4
11	17	11	39	25	27.8
12	18	4	6	3	4.4
13	19	8	9	21	13.6
14	20	2	2	4	2.8
15	21	8	19	35	23.2
16	22	2	12	10	9.2
17	23	9	2	9	6.2
18	24	14	18	6	12.4
19	25	30	3	6	9.6

가중치를 부여하여 RFM 점수 산출  
(가중치: R = 0.2, F = 0.4, M = 0.4)

구매 기간(R), 주문 빈도(F), 주문 상품 수(M) 를 바탕으로 **RFM 점수 계산**

## 03 RFM & 고객 세분화

파생 변수 생성 및 고객 등급 분류

### 파생변수 생성

RFM 변수 도출 2단계

1) 클러스터 수 설정

```
1 from sklearn.metrics import silhouette_score
2 from sklearn.cluster import KMeans
3
4 # KMeans 클러스터링 수행 (n_clusters = 5)
5 kmeans = KMeans(n_clusters=5)
6 kmeans.fit(rfm_model[['rfm_score']])
7
8 # 실루엣 계수 계산
9 silhouette_avg = silhouette_score(rfm_model[['rfm_score']], kmeans.labels_)
10 print(f"Silhouette Score: {silhouette_avg}")
```

# 클러스터 품질 판단(실루엣 계수)			
3	4	5	6
0.646	0.599	0.576	0.548

# 실루엣 계수를 이용해 최적의 클러스터 수 선택

# 3-6 모두 적절한 클러스터링 품질을 확인함

# 각 고객의 특성을 세분화하기 위해 5개로 설정

2) k-means 를 통해 고객 분류

(1) 클러스터 범위 확인


클러스터 1 : 0 - 9  
클러스터 2 : 9 - 20  
클러스터 3 : 20 - 37  
클러스터 4 : 37 - 64  
클러스터 5 : 64 - 106  
클러스터 6 : 106 - 244

(2) 고객 등급 부여

클러스터 범위별 고객 등급		
클러스터	고객 등급	설명
6	VIP	최고 수준의 구매 활동을 보이며, 자주 구매
5	최우수	우수한 구매 활동과 주문수를 보임
4	우수	높은 재구매 주기와 주문수를 보임
3	잠재 우수	구매 빈도가 점차 지는 고객
2	일반 고객	중간 수준의 재구매 주기와 빈도를 보임
1	이탈 위험	구매주기가 길고 낮은 주문수를 보임

(3) 고객 등급별 비율 확인

VIP 고객 : 685 (0.56%)  
최우수 고객 : 4,194 (3.41%)  
우수 고객 : 11,255 (9.16%)  
잠재 우수 고객 : 25,760 (19.80%)  
일반 고객 : 55,880 (45.50%)  
이탈 위험 고객 : 25,038 (20.40%)

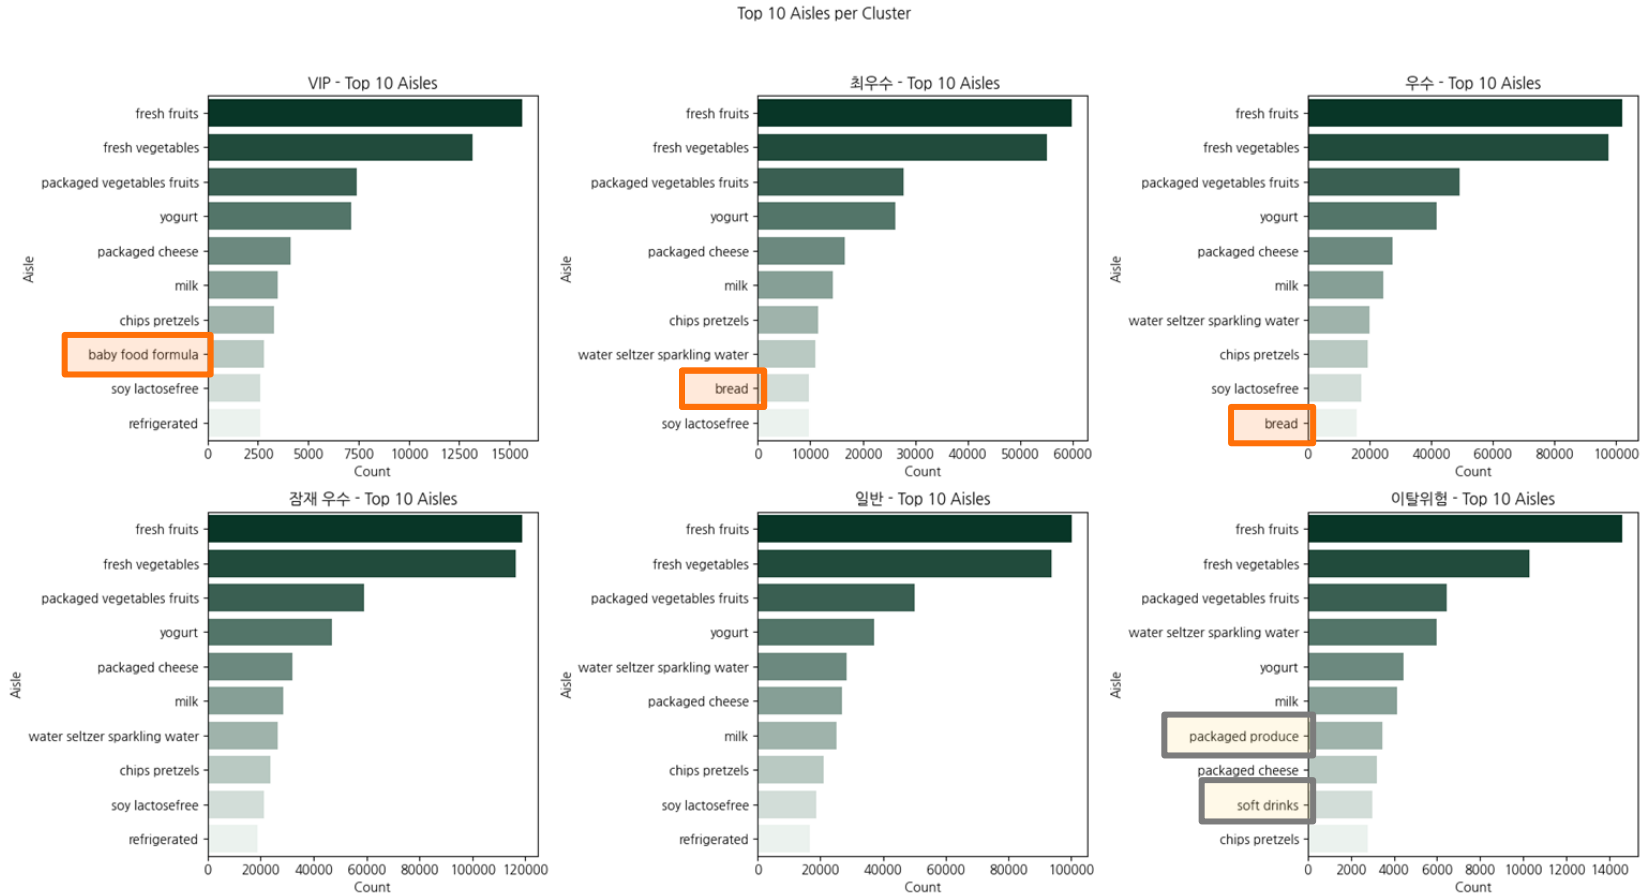


K-means 알고리즘을 활용하여, **RFM 점수 기반으로 고객 등급 산출**

## 04 고객 세분화별 EDA

고객 insight

### Q1. 그룹별 가장 많이 주문된 중분류 상품(Aisle)은?



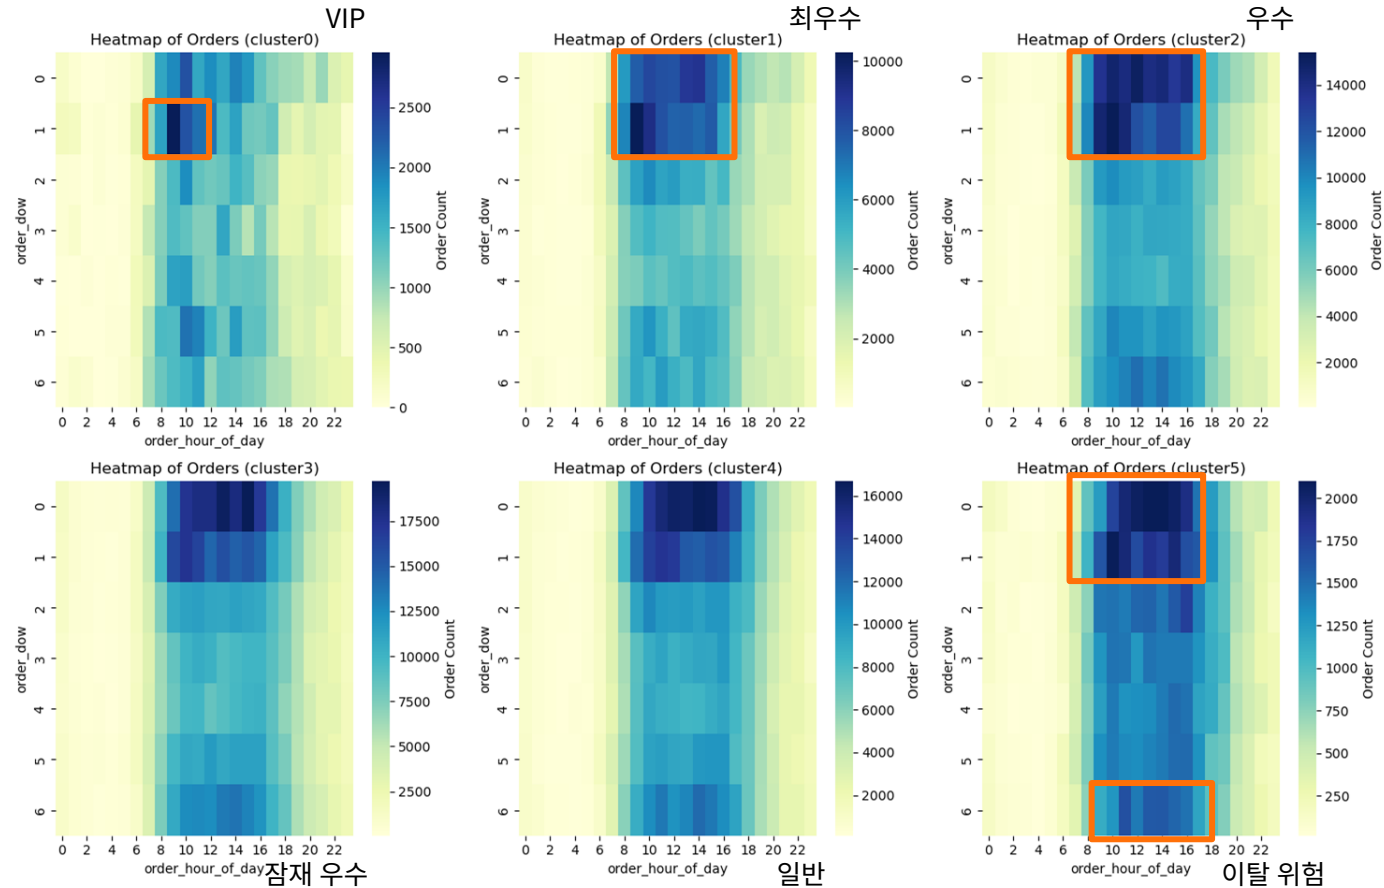
가장 많이 주문한 중분류 상품은 Fresh fruits

VIP 그룹에만 보이는 품목 = baby food formula 분류

최우수, 우수 그룹에만 보이는 품목 = bread

이탈 위험 그룹에만 보이는 품목 = soft drinks, packaged produce

## Q2. 그룹별 가장 많이 주문하는 요일과 시간대는?




월요일 오전 9시가 가장 활발하며, 이탈 위험 고객은 토요일 10-16시 사이에 높은 활성화를 보임

## 04 고객 세분화별 EDA

고객 insight

### Q3. 그룹별 재구매까지 걸리는 기간은?



| Department 별 유니크한 품목 수 |

cluster	avg
VIP 고객	124.216769
최우수 고객	85.853578
우수 고객	57.417448
잠재 우수 고객	34.220248
일반 고객	14.802362
이탈 위험 고객	4.729342

| Aisle 별 유니크한 품목 수 |

cluster	avg
VIP 고객	44.713701
최우수 고객	36.801864
우수 고객	28.430051
잠재 우수 고객	19.893015
일반 고객	10.331916
이탈 위험 고객	3.915115

처음 구매(-1) 제외 후 이탈 위험 고객 재구매가 경험이 적음


우수 고객 이상은 확실히 재구매 주기가 짧음

고객 등급이 높을 수록 다양한 상품을 경험(구매)함


## 04 고객 세분화별 EDA

고객 insight

### Q3 - 1. 그룹별 재구매 비율 변화는?



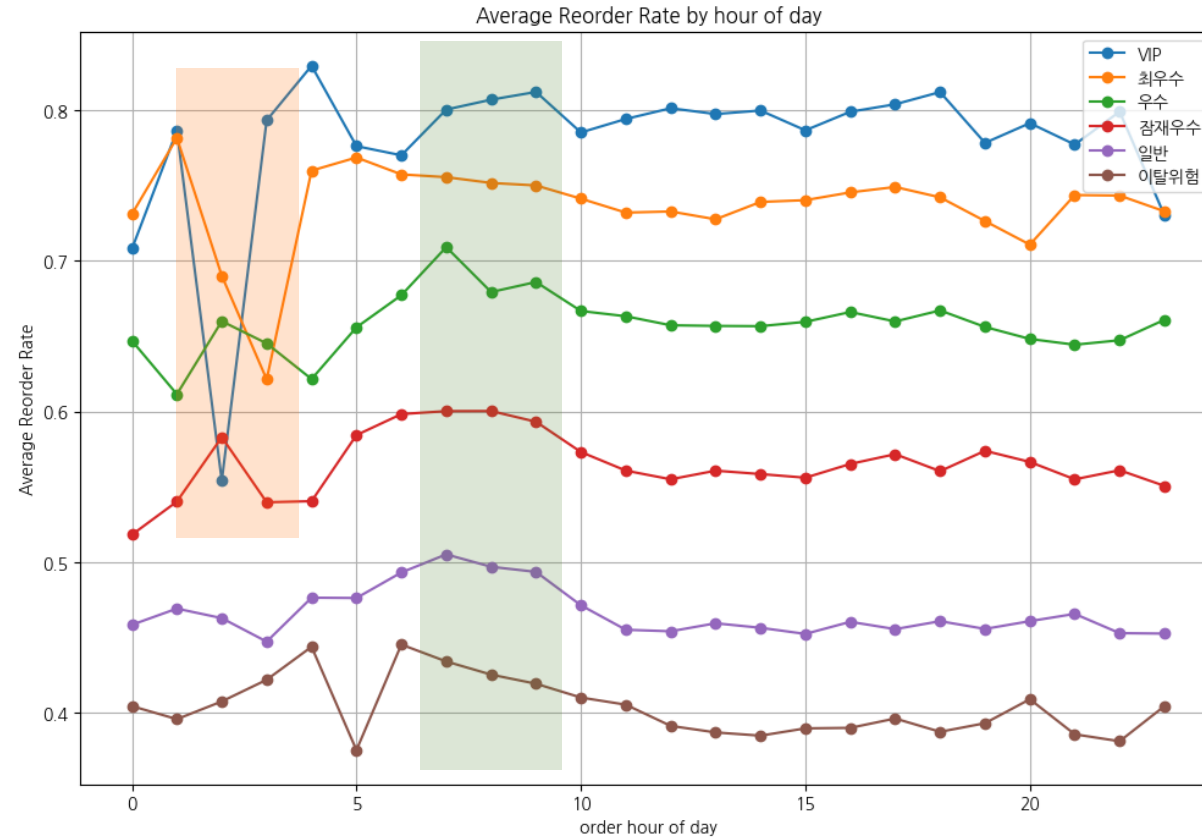
각 고객의 등급이 높을수록 **재구매 상품 증가**



전체 고객 중 우수 고객 이상의 비율은 13%지만,  
전체 주문 수의 35.4%, 전체 주문 상품 수는 43.9% 를 차지



## Q3 - 2. 등급별 재구매가 가장 많이 일어나는 시간대는?

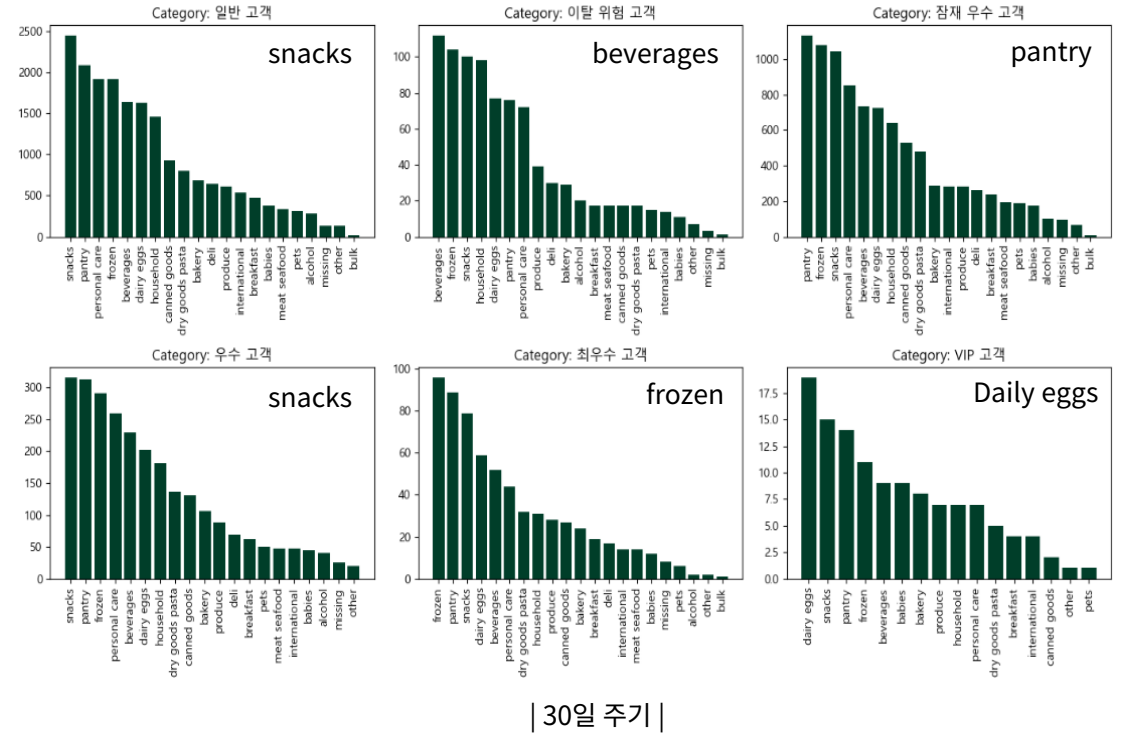
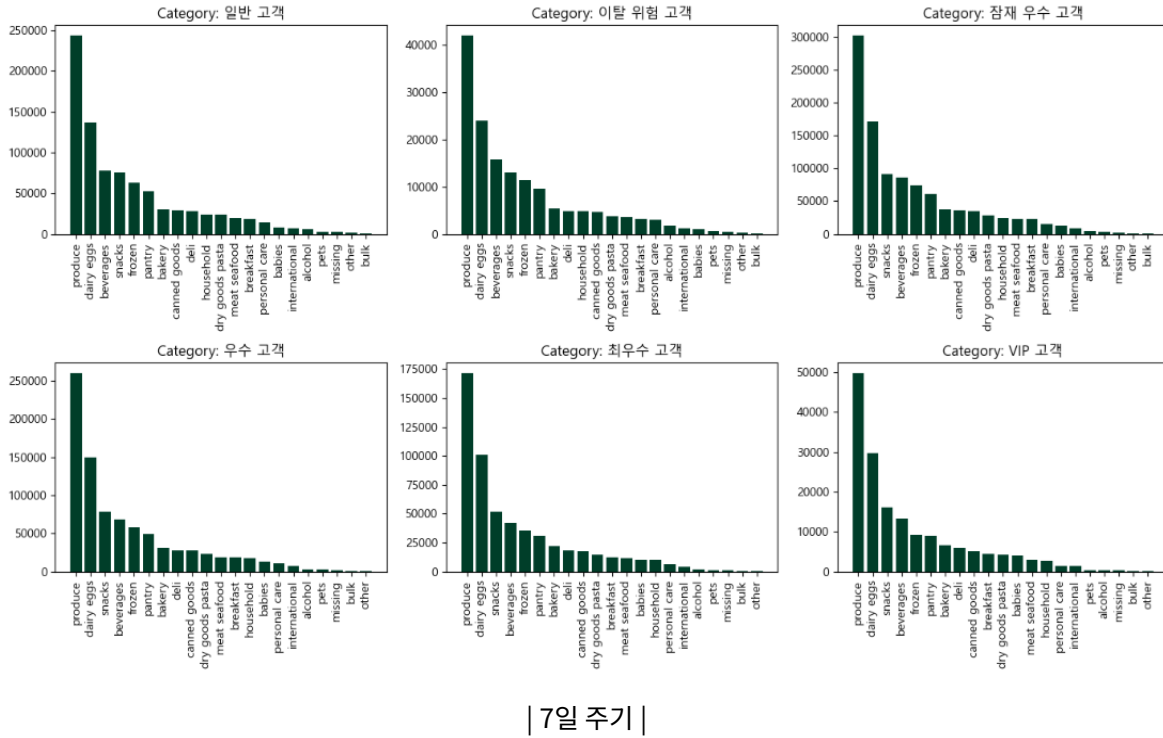


오전 7시-9시 재구매율 높음, 새벽 2-3시 VIP 및 최우수 고객의 일회성 구매 발생함

## 04 고객 세분화별 EDA

고객 insight

### Q4 - 3. 주기별 재구매 인기 상품은?



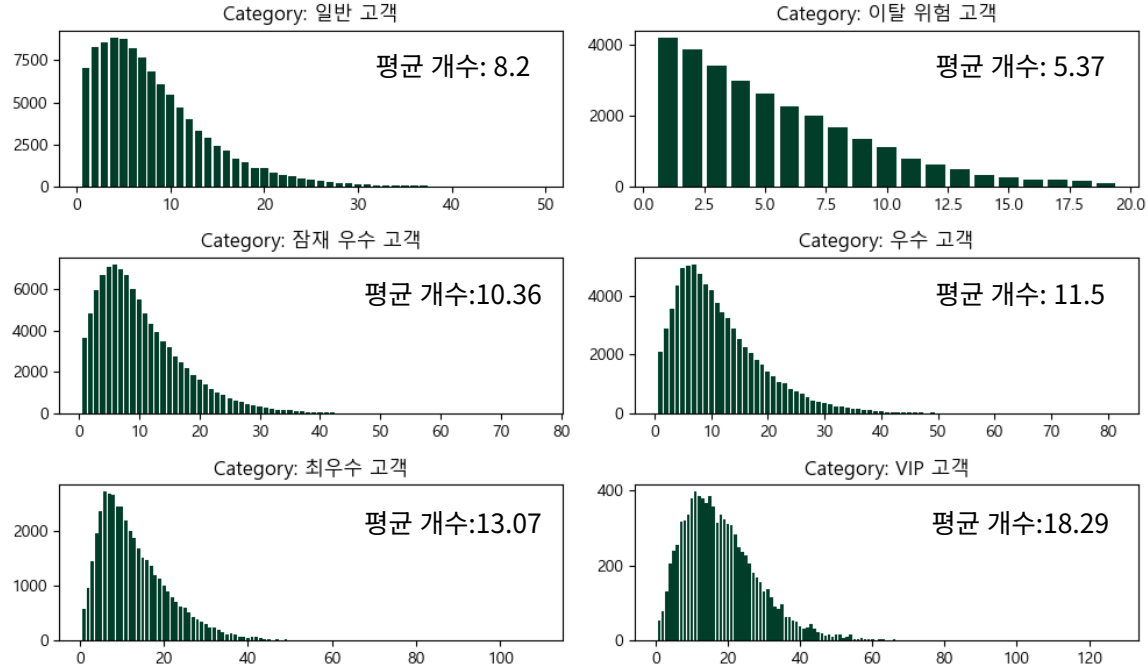
7일 주기 인기 상품은 TOP 1 은 **Produce** , 30일 이후 주기는 **그룹별로 다름**

## 04 고객 세분화별 EDA

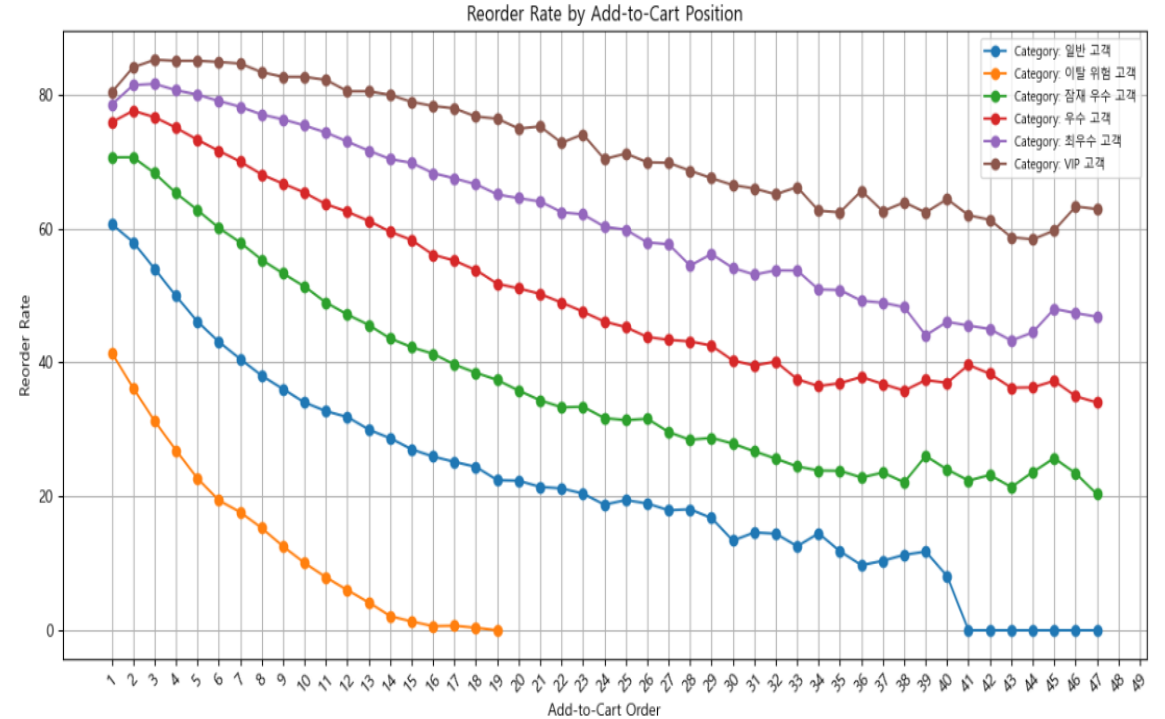
고객 insight

### Q5. 주문 시 평균 장바구니 물품 수는?

| 그룹별 평균 장바구니 물품 수 |



| 장바구니 순서에 따른 재구매율 |



등급 별로 주문 시 담는 **물품의 개수가 증가**하며, 일반 고객은 40개 이상부터는 새로운 상품을 구매

Features 생성

고객 중심 기반으로 기존 Feature 3개에 더해 총 20개 Feature 사용

Features		Description
user_id		주문을 한 고객의 고유 식별자입니다.
product_id		상품의 고유 식별자입니다.
reordered		재구매된 상품인지를 나타냅니다
uxp_times_bought		user_id 와 product_id를 기준으로 사용자가 해당 제품을 몇 번 주문했는지 나타냅니다.
uxp_reorder_ratio		사용자가 특정 제품을 처음 구매한 이후 해당 제품을 얼마나 자주 재구매 했는지 계산한 비율입니다.
uxp_last_five		최근 5회 주문에서 사용자별 특정 제품의 구매 횟수입니다.
uxp_ratio_last_five		최근 5회 주문 중 제품 구매 비율(uxp_ratio_last_five)을 계산하여 해당 제품의 최근 주문에서의 중요성을 나타냅니다.
u_num_of_orders		각 user_id에 대해 order_number의 최대값을 구하여 사용자별 총 주문 횟수를 계산합니다.
u_avg_prd		user_id와 order_id별로 각 주문에 포함된 제품 수를 구한 후 사용자별 평균 주문 제품 수입니다.
dow_u_most_order		각 user_id별로 가장 많이 주문한 요일입니다.
hod_u_most_orders		각 user_id별로 가장 많이 주문한 시간대입니다.
u_reorder_ratio		각 user_id별로 재주문된 비율입니다.
p_num_of_times		각 product_id별로 총 구매된 횟수입니다.
p_reorder_ratio		각 product_id별로 재주문된 비율입니다.
p_avg_cart_position		각 product_id별로 장바구니에 추가된 평균 위치입니다.
uxp_times_ratio		사용자가 마지막 5회 구매에서 특정 상품을 얼마나 자주 구매했는지를 나타내는 비율입니다.
log_u_num_of_orders		사용자의 총 주문 수에 대한 로그 변환 값입니다.
order_time_combined		사용자가 가장 많이 주문한 요일과 시간대를 합친 값입니다.
reorder_diff		사용자의 재구매 비율과 상품의 재구매 비율 차이를 나타냅니다.
uxp_time_to_last_ratio		사용자가 특정 상품을 구매한 횟수와 최근 5회 구매에서 해당 상품을 구매한 횟수의 비율입니다.

※강조 부분은 제일 나중에 추가된 피처입니다.

재구매 예측을 위한 모델 선택

CatBoost



CatBoost

장점

범주형 변수 처리	범주형 변수는 자동 인식해 시간 단축
성능	다양한 유형에서 높은 정확도를 보임
과적합 방지	정규화와 부스팅 방식을 통해 과적합을 효과적으로 방지
빠른 처리 속도	LightGBM 과 유사한 속도를 보임

단점

속도	연속형 변수만 있는 데이터는 다소 느림
메모리 사용	대형 데이터셋에서는 많은 메모리 사용

XG Boost



장점

병렬 학습	분산 학습 지원으로 더 빠른 학습 제공
성능	다른 모델보다 좋은 성능을 보임
규제	L1/L2 규제 기능으로 과적합을 방지
변수 중요도	변수의 중요도를 추정할 수 있어, 모델 해석에 유리

단점

속도	LightGBM 보다 상대적으로 느림
메모리 사용	LightGBM 보다 많이 소비할 수 있음

LightGBM



LightGBM

장점

속도	다른 모델보다 빠르게 학습하고 예측
메모리 효율성	적은 메모리로 대규모 데이터 셋에 강함
과적합에 강함	다양한 트리를 합성하여 과적합을 어느 정도 방지
변수 중요도 추정	변수 중요도를 잘 제공하여, 해석 가능

단점

과적합 위험	하이퍼파라미터 튜닝을 잘못하면 과적합이 발생할 수 있음
--------	--------------------------------

고객 재구매 예측을 위해 결정 트리 기반의 머신러닝 모델 확인

## 05 재구매 예측 모델

### Modeling

## 1차 LightGBM 모델 이용

총 15개의 피쳐로 1차 진행

```
lgbm = lgb.LGBMClassifier(objective='binary', num_leaves=96, max_depth=10)
lgbm.fit(X_train, y_train)
```

[LightGBM] [Info] Number of positive: 580657, number of negative: 5351605  
[LightGBM] [Info] Auto-choosing row-wise multi-threading, the overhead of testing was 0.050590 seconds.  
You can set 'force\_row\_wise=true' to remove the overhead.  
And if memory is not enough, you can set 'force\_col\_wise=true'.  
[LightGBM] [Info] Total Bins 1735  
[LightGBM] [Info] Number of data points in the train set: 5932262, number of used features: 12  
[LightGBM] [Info] [binary:BoostFromScore]: pavg=0.097881 -> initscore=-2.220992  
[LightGBM] [Info] Start training from score -2.220992

LGBMClassifier  
LGBMClassifier(max\_depth=10, num\_leaves=96, objective='binary')

### 피팅 모델 성능 평가

F1 Score: 0.43276622774639906				
	precision	recall	f1-score	support
0	0.91	0.94	0.93	2208076
1	0.51	0.38	0.43	334323
accuracy			0.87	2542399
macro avg	0.71	0.66	0.68	2542399
weighted avg	0.86	0.87	0.86	2542399

1차 전체 데이터 모델의 성능 결과

**F1 Score 0.43 확인**, 추가적으로 심한 데이터 불균형도 확인

## 2차

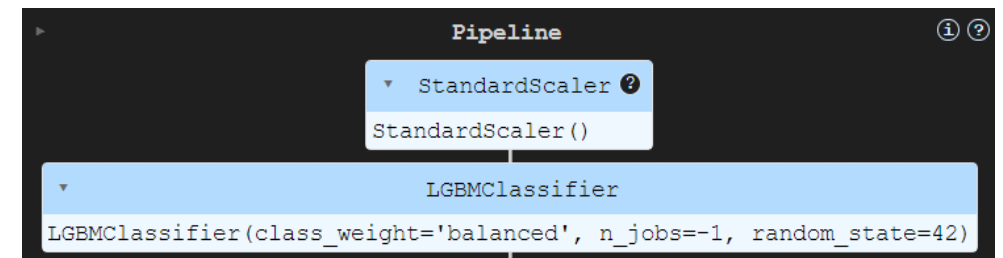
피쳐 추가 및 훈련 데이터에 SMOTE 오버샘플링 적용

```
# `reordered`가 0인 데이터와 1인 데이터의 비율을 맞추기 위해 SMOTE 적용
X = data_sampled[features]
y = data_sampled['reordered']
```

reordered	
1.0	7645837
0.0	7645837
Name: count, dtype: int64	

```
# SMOTE로 오버샘플링 (클래스 1에 대해)
smote = SMOTE(random_state=42)
X_resampled, y_resampled = smote.fit_resample(X, y)
```

모델 파이프라인 구성(표준화 + 각 모델 사용)



데이터 불균형 해소를 위한 **SMOTE 오버 샘플링 적용**과

함께 **모델 파이프 라인**을 추가

## 05 재구매 예측 모델

Model evaluation

### 모델 평가

#### CatBoost



CatBoost

```
F1 Score: 0.936542554769004
Accuracy: 0.9393562157371667
Classification Report:
              precision    recall  f1-score   support

    0.0         0.90      0.98      0.94     458113
    1.0         0.98      0.89      0.94     459244

 accuracy          0.94
 macro avg         0.94
 weighted avg      0.94
```

F1 Score = 0.936

Accuracy = 0.939

#### XG Boost

*XGBoost*

```
F1 Score: 0.9244526517407919
Accuracy: 0.9281108663257598
Classification Report:
              precision    recall  f1-score   support

    0.0         0.89      0.98      0.93     458113
    1.0         0.98      0.88      0.92     459244

 accuracy          0.93
 macro avg         0.93
 weighted avg      0.93
```

F1 Score = 0.924

Accuracy = 0.928

#### LightGBM



LightGBM

```
F1 Score: 0.9231552145433638
Accuracy: 0.9265803124902929
Classification Report:
              precision    recall  f1-score   support

    0.0         0.89      0.97      0.93     1529441
    1.0         0.97      0.88      0.92     1528894

 accuracy          0.93
 macro avg         0.93
 weighted avg      0.93
```

F1 Score = 0.923

Accuracy = 0.926

최종 모델 성능 결과, **CatBoost 모델이 94%의 정확도로 재구매 예측이 가능함**

## 06 결론 및 제안

### 분석 결과 요약

#### 고객 주요 선호 상품

Instacart 속 고객 주요 선호 상품은 **Produce** 농산물로 fruits & vegetables 가 약 30% 차지합니다.

가장 인기가 많은 제품은 1, 2위 모두 **바나나**로 약 85만건 구매가 일어났습니다.

#### 고객 활동 피크 시간대

**일요일&월요일** 높은 구매율을 보이고 있습니다.

메인 시간으로 **오전 9시에서 오후 5시**까지가 가장 활성화되며, **재구매는 특히 6-7시, 21시**에 가장 많이 일어났습니다.

#### 재구매 활성화: 7일고

약 94%가 재구매 경험이 있으며, 주문 중 재구매 비율은 약 59%로, **주로 7일 이내 또는 30일**을 주기로 많은 재구매가 일어났습니다.

**7일** 주기로는 **Produce** 농산물이, **30일** 주기로는 **Personal Care**가 주문되었습니다.

#### VIP 고객

구매 주기도 짧고, 구매빈도 많은 고객으로 **평균 19개의 상품을 주문하며**, Baby food formula 수요가 존재합니다.  
**월요일 오전9시에 가장 많은 구매활동을** 하고 있습니다.

#### 일반 & 잠재 우수 고객

전체 고객들 중 **가장 많은 비율을 차지합니다.**  
일반고객(45.5%), 잠재우수 고객(19.8%)

**일반 고객은 최근에 유입된 고객들로** 보이며, 잠재 우수 고객은 구매 빈도가 낮아집니다.

#### 장바구니 속 구매 형태

대부분 고객들은 **평균 8개 정도의 물품**을 장바구니에 담아 주문하고 있습니다.

가장 빨리 넣는 상품은 자주 구매하는 상품들로 순서에 따라 연관이 있습니다.

#### 최우수 & 우수 고객

**평균 11-13개의 상품을 주문하며**, Bread 에 대한 수요가 존재합니다.

주로 일요일, 월요일이며 오전 9시에서 17시까지 활발한 구매행동을 하고 있습니다.

#### 이탈 위험 고객

**재구매 빈도가 낮고** 한 번 구매할 때, 매우 적은 양을 구합니다.

**인기 품목은 beverages(soft drinks)**가 구매가 많이 일어납니다.

#### 재구매 예측 모델

고객 중심 Features 를 기반으로 CatBoost을 활용한 재구매 상품 추천 시스템은 **약 94%의 정확도로 고객의 재구매율 가능성을 파악**할 수 있습니다.



## 06 결론 및 제안

전략 제안 및 기대효과

### 그룹별 TOP 10 인기 상품 추천

그룹별로 인기 있는 TOP10 상품을 기반으로 추천하고, 특히, 바나나와 같은 인기 상품을 중심으로 함께 자주 구매되는 상품을 추천함으로써, **고객의 추가 구매 의사를 증가**시키는 효과를 기대할 수 있습니다.

### 피크 타임을 활용한 전략적인 마케팅 활동

일요일 & 월요일, 오전 9시부터 오후 5시까지 활동이 많다는 점을 고려하여, 해당 시간대에 한정 할인 이벤트 또는 마케팅에 집중하여 **판매 증가와 함께 효율적인 마케팅 비용 관리**를 기대할 수 있습니다.

### 7일 및 30일 주기를 활용한 재구매 알림

재구매가 가장 많이 일어나는 7일과 30일 주기로 그룹별 인기상품을 리마인더하여, **효율적으로 재구매를 유도**할 수 있습니다.

리마인더와 함께 특별 할인이나 포인트 적립 혜택을 제공하면, 고객의 재구매를 더욱 유도할 수 있습니다.

### VIP 고객 중심

월요일 오전 9시에 유아 식품과 관련된 **번들 상품 프로모션**을 진행하여, 매출을 극대화하고 높은 고객 경험을 제공할 수 있습니다.

### 최우수 & 우수 고객 중심

일요일, 월요일이며 오전 9시부터 17시까지 **bread, dairy eggs** 중심으로 **프로모션**을 진행하면 많은 판매 효과를 기대할 수 있습니다.

### 일반 & 잠재 우수 고객

맞춤형 추천 상품과 초기 구매를 유도하는 번들 할인을 통해 구매 빈도를 높이고 지속적으로 관심을 유지하게 하여 충성 고객으로의 전환을 기대할 수 있습니다.

### 이탈 위험 고객 중심

**Soft drinks** 관련 소량 구매 유도 **프로모션**을 통해 재구매를 촉진하여, 재구매 빈도를 점차 늘이는 효과를 기대할 수 있습니다.

### 장바구니 추천 번들 상품

자주 구매하는 상품 중에서 함께 들어가는 상품 조합을 번들로 묶어 추천하여, 고객에게 **한 번에 많은 상품 구매**를 유도할 수 있습니다.

### 재구매 상품 추천 시스템

고객의 재구매 패턴을 이해함으로써 고객과의 관계를 더욱 강화할 수 있는 기회를 제공하며, **장기적인 충성도**를 구축하는데 기여할 수 있습니다.

**감사합니다.**